

ANONYMIZED FIDELITY - DESCRIZIONE

domenica 13 settembre 2026 11:40

MICCICHÈ FLAVIO - 1000059576

Il dataset analizzato è **AnonymizedFidelity.csv**, contenente informazioni sugli acquisti effettuati dai clienti di un supermercato. Ogni osservazione del dataset descrive un singolo prodotto acquistato all'interno di uno scontrino e include, in particolare, le seguenti informazioni principali:

- identificativo scontrino;
- descrizione del prodotto acquistato in vari livelli;
- prezzo;
- data e ora;
- tessera fedeltà;

L'obiettivo dell'elaborato è quello di applicare diverse tecniche di data mining al fine di analizzare i comportamenti di acquisto dei clienti. In particolare, le attività svolte sono:

- analisi delle frequenze;
- analisi stratificata per osservare le variazioni temporali;
- estrarre le regole di associazione (mediante algoritmi apriori e fpgrowth);
- clustering con PCA, per individuare gruppi di clienti con comportamenti di acquisto simili.

Prima di procedere con le analisi, il dataset è stato sottoposto a una fase di preprocessing, migliorando la qualità dei dati e rendendoli adeguati al contesto dell'analisi.

Sono state rimosse alcune feature non rilevanti (non coinvolte nell'analisi) al fine di ridurre la complessità computazionale (dato che il file pesa 850 MB+). Successivamente, come richiesto dalla traccia, sono stati esclusi dai dataset gli articoli aventi il valore "shopper" nella variabile **descr_liv4**.

Le feature contenenti informazioni temporali, ossia data e ora, sono state convertite da *object* (stringhe) a *datetime*. Questa conversione è necessaria al fine di estrarre il mese e ore/minuti. Infine, si è effettuata un'operazione di feature engineering, creando le feature derivate:

- **fascia_mese**, che suddivide gli acquisti in tre intervalli:
 - RANGE 1: da gennaio a metà maggio;
 - RANGE 2: da metà maggio a settembre;
 - RANGE 3: da ottobre a dicembre.
- **fascia_oraria**, che suddivide la giornata in tre fasce temporali:
 - SLOT 1: 08:30 – 12:30;
 - SLOT 2: 12:30 – 16:30;
 - SLOT 3: 16:30 – 20:30.

Lavorando su una versione più pulita e compatta permette di ottenere risultati non ambigui in minor tempo.


TASK 1

L'analisi delle frequenze di acquisto dei prodotti ha permesso di identificare categorie dei prodotti maggiormente acquistate e quelle meno rappresentate, fornendo una prima visione d'insieme delle preferenze dei consumatori.

Il **livello 1** descrive il prodotto in modo generico e, di conseguenza, sotto la stessa categoria possono essere raggruppati molti prodotti differenti. Dall’analisi delle frequenze emerge che le categorie tipicamente vendute in supermercati risultano essere le presenti nel dataset, come ad esempio la drogheria alimentare. Il **livello 2** approfondisce maggiormente la tipologia del prodotto. Dall’analisi emerge che i prodotti freschi e di prima necessità dominano la classifica (superando le 120.000 occorrenze). Al contrario, le categorie meno frequenti riguardano articoli marginali non pertinenti con ciò che vende in genere un supermercato (telefonia).

Il **livello 3** scende ulteriormente nei dettagli merceologici. Dall’analisi delle frequenze emerge una chiara prevalenza dei prodotti da banco assistito e dei beni di largo consumo, evidenziando l’importanza del servizio al banco. Al contrario, articoli molto specifici, non del settore, sono acquistati dai clienti, indicando che saranno prodotti residuali.

Ultimo è il **livello 4**, che indica direttamente il nome del prodotto (non prendendo una categoria più ampia). Dalle analisi emerge che gli alimenti di consumo quotidiano dominano la classifica, mentre oggetti estremamente particolari registrano un solo acquisto.





In generale si è visto come i generi alimentari di consumo quotidiano prevalgano durante gli acquisti e come articoli di nicchia o che solitamente sono acquistati in altre attività vengano ignorati dai clienti.

TASK 2

Ma durante l'anno o durante il giorno, gli acquisti sono gli stessi? O a seconda del periodo (sia breve che lungo) la tipologia del prodotto acquistato cambia?

Analizziamo inizialmente gli acquisti per livello durante l'anno e verifichiamo eventuali variazioni.





L'analisi stratificata temporale, evidenzia che le abitudini sono abbastanza stabili con drogheria alimentare e fresco predominanti in tutti e tre i periodi.

Se si analizza il livello 4, quello dei prodotti dettagliati, notiamo che i prodotti d'uso quotidiano (pane, prosciutto,...) sono quegli più acquistati indipendentemente dalla stagione.

Tornando al livello 1, in estate si registra un leggero aumento di bevande e di prodotti freschi, ad evidenziare che, pur con una struttura d'acquisti stabile, le frequenze di alcuni prodotti variano a seconda della stagione.

Analizziamo invece gli acquisti per livello a seconda della fascia oraria, verificando le possibili variazioni.



L'analisi per fascia oraria fornisce un'interessante interpretazione del comportamento dei clienti durante la giornata. Si ha che:

- **Mattina (slot 1):** fascia dominante è quella del pane e il fresco di giornata;
- **Primo pomeriggio (slot 2):** si registra un calo nelle vendite e si hanno gli stessi prodotti più venduti però con frequenze minori;
- **Tardo pomeriggio (slot 3):** il volume degli acquisti risale e la spesa è più strutturata, dato che la categoria predominante è "Normale" (descrLiv4). "Normale" identifica la variante standard di prodotti di largo consumo (caffè, burro o carta igienica). Ciò indica una spesa più orientata al rifornimento piuttosto che al consumo diretto.

TASK 3 & TASK 4

Dopo aver analizzato la distribuzione delle frequenze e le variazioni temporali, l'attenzione si sposta sull'individuazione di relazioni tra prodotti acquistati insieme. Secondo quanto studiato durante il corso abbiamo visto due algoritmi principali:

- **Apriori;**
- **Fpgrowth;**

Indipendentemente dall'algoritmo utilizzato si è scelto di analizzare le regole di associazione $A \rightarrow B$ e valutarle attraverso le metriche:

- **Support**, che indica la frequenza con cui una coppia appare nelle stesse transazioni;
- **Confidence**, che misura la probabilità di acquistare B dato A;
- **Lift**, che indica quanto una regola di associazione è realmente utile.

```
APRIORI threshold = 0.05 confidence = 0.2 maxnumrules = 20
antecedents      consequents  support  confidence  lift
A                (A,B,C,D,E)  0.067212  0.367215  2.155022
```

APRIORI threshold = 0.05 confidence = 0.2 maxnumrules = 20					
	antecedents	consequents	support	confidence	lift
0	(BOVINO)	(AVICUNICOLO)	0.062342	0.367315	2.155022
1	(AVICUNICOLO)	(BOVINO)	0.062342	0.365761	2.155022
2	(AVICUNICOLO)	(PANETTERIA PANE)	0.050823	0.298174	1.098589
3	(PROSCIUTTO COTTO)	(AVICUNICOLO)	0.050816	0.202622	1.188774
4	(AVICUNICOLO)	(PROSCIUTTO COTTO)	0.050816	0.298136	1.188774
5	(PANETTERIA PANE)	(BOVINO)	0.061426	0.226318	1.333444
6	(BOVINO)	(PANETTERIA PANE)	0.061426	0.361917	1.333444
7	(PROSCIUTTO COTTO)	(BOVINO)	0.051466	0.205213	1.209090
8	(BOVINO)	(PROSCIUTTO COTTO)	0.051466	0.303231	1.209090
9	(NORMALE)	(GRANA E SIMILI)	0.053337	0.214105	1.399969
10	(GRANA E SIMILI)	(NORMALE)	0.053337	0.348755	1.399969
11	(PROSCIUTTO COTTO)	(GRANA E SIMILI)	0.066436	0.264903	1.732124
12	(GRANA E SIMILI)	(PROSCIUTTO COTTO)	0.066436	0.434404	1.732124
13	(NORMALE)	(LATTE VACCINO)	0.065396	0.262513	1.472084
14	(LATTE VACCINO)	(NORMALE)	0.065396	0.366720	1.472084
15	(PROSCIUTTO COTTO)	(LATTE VACCINO)	0.076624	0.305526	1.713288
16	(LATTE VACCINO)	(PROSCIUTTO COTTO)	0.076624	0.429680	1.713288
17	(PROSCIUTTO COTTO)	(MORTADELLA)	0.052915	0.210990	2.353630
18	(MORTADELLA)	(PROSCIUTTO COTTO)	0.052915	0.590273	2.353630
19	(NORM.ASC.CORTA)	(NORMALE)	0.051160	0.382474	1.535324

FP-GROWTH threshold = 0.05 confidence = 0.2 maxnumrules = 20					
	antecedents	consequents	support	confidence	lift
0	(PROSCIUTTO COTTO)	(PANETTERIA PANE)	0.076845	0.306407	1.128922
1	(PANETTERIA PANE)	(PROSCIUTTO COTTO)	0.076845	0.283125	1.128922
2	(PROSCIUTTO COTTO)	(NORMALI)	0.059685	0.237985	1.373528
3	(NORMALI)	(PROSCIUTTO COTTO)	0.059685	0.344471	1.373528
4	(NORMALE)	(NORMALI)	0.067034	0.269085	1.553020
5	(NORMALI)	(NORMALE)	0.067034	0.386883	1.553020
6	(PROSCIUTTO COTTO)	(SALAME)	0.059756	0.238270	2.420416
7	(SALAME)	(PROSCIUTTO COTTO)	0.059756	0.607023	2.420416
8	(PROSCIUTTO COTTO)	(LATTE VACCINO)	0.076624	0.305526	1.713288
9	(LATTE VACCINO)	(PROSCIUTTO COTTO)	0.076624	0.429680	1.713288
10	(NORMALE)	(LATTE VACCINO)	0.065396	0.262513	1.472084
11	(LATTE VACCINO)	(NORMALE)	0.065396	0.366720	1.472084
12	(PROSCIUTTO COTTO)	(PASTE FILATE STAGIONATE)	0.077234	0.307961	2.272618
13	(PASTE FILATE STAGIONATE)	(PROSCIUTTO COTTO)	0.077234	0.569956	2.272618
14	(NORM.ASC.CORTA)	(NORMALE)	0.051160	0.382474	1.535324
15	(NORMALE)	(NORM.ASC.CORTA)	0.051160	0.205368	1.535324
16	(PROSCIUTTO COTTO)	(MORTADELLA)	0.052915	0.210990	2.353630
17	(MORTADELLA)	(PROSCIUTTO COTTO)	0.052915	0.590273	2.353630
18	(PROSCIUTTO COTTO)	(NORMALE)	0.080288	0.320138	1.285094
19	(NORMALE)	(PROSCIUTTO COTTO)	0.080288	0.322292	1.285094
20	(NORMALE)	(PANETTERIA PANE)	0.062843	0.252263	0.929434
21	(PANETTERIA PANE)	(NORMALE)	0.062843	0.231537	0.929434
22	(PROSCIUTTO COTTO)	(AVICUNICOLO)	0.050816	0.202622	1.188774
23	(AVICUNICOLO)	(PROSCIUTTO COTTO)	0.050816	0.298136	1.188774
24	(PANETTERIA PANE)	(AVICUNICOLO)	0.050823	0.187250	1.098589
25	(AVICUNICOLO)	(PANETTERIA PANE)	0.050823	0.298174	1.098589
26	(PROSCIUTTO COTTO)	(GRANA E SIMILI)	0.066436	0.264903	1.732124
27	(GRANA E SIMILI)	(PROSCIUTTO COTTO)	0.066436	0.434404	1.732124
28	(NORMALE)	(GRANA E SIMILI)	0.053337	0.214105	1.399969
29	(GRANA E SIMILI)	(NORMALE)	0.053337	0.348755	1.399969

Dal confronto e l'analisi dei risultati emersi dai due algoritmi, notiamo:

- Che i due algoritmi estraggono gli **stessi identici dati**. La differenza nell'output dipende solo dall'ordinamento e dalle soglie nel main diverse, ma nonostante tutto alcune righe coincidono al millesimo (si guardi la regola Prosciutto Cotto -> Mortadella alla riga 17 di Apriori e riga 16 di FP-Growth);

- I migliori 3 Pattern INTERESSANTI (Lift > 1):

1. **PROSCIUTTO COTTO -> SALAME** (Lift: 2.42 | Confidence: 23.8%)

Ha il Lift più alto in assoluto. Sebbene la confidenza sia moderata, chi compra salame ha una probabilità altissima (60.7%) di comprare anche prosciutto cotto. Indica una forte tendenza alla spesa mirata nel reparto salumeria.

2. **PROSCIUTTO COTTO -> MORTADELLA** (Lift: 2.35 | Confidence: 21.1%)

Simile al caso precedente. Chi compra mortadella acquista anche prosciutto cotto il 59% delle volte. Conferma l'esistenza di un paniere specifico dedicato agli affettati/salumi.

3. **PASTE FILATE STAGIONATE -> PROSCIUTTO COTTO** (*Lift: 2.27 | Confidence: 57.0%*)

Ottima combinazione. Più della metà dei clienti che acquista un formaggio stagionato a pasta filata (es. provola, scamorza) ci abbina il prosciutto cotto. È un'associazione gastronomica classica e solida.

- Pattern FREQUENTI ma NON INTERESSANTI ($Lift < 1$ oppure $Lift \approx 1$):

1. **NORMALE -> PANETTERIA PANE** (*Lift: 0.93 | Support: 6.2%*)

leggera indipendenza (o dissociazione). Comprare un prodotto di categoria "Normale" (caffè, burro o carta igienica) non incentiva l'acquisto del pane;

2. **AVICUNICOLO -> PANETTERIA PANE** (*Lift: 1.09 | Support: 5.0%*)

L'acquisto di carne bianca (pollo/coniglio) e del pane avviene in modo del tutto indipendente. La regola ha un buon supporto solo perché sono due articoli molto venduti nel supermercato.

Nell'insieme, i salumi rappresentano il nucleo centrale delle associazioni, sia per acquisti immediati che per quelli più articolati, e il pane è un prodotto acquistato in maniera indipendente a qualsiasi altro prodotto (pollo, caffè,...) poiché di prima necessità.

Infine possiamo affermare che, data l'elevata numerosità di osservazioni nel dataset, i valori di supporto risultano relativamente bassi.

TASK 5

Dopo che si sono studiate le principali relazioni tra prodotti mediante le regole di associazione, l'analisi si è concentrata sull'individuazione di gruppi di clienti (tesserati) con comportamenti di acquisti simili.

Dato che il dataset è molto grande, si è scelto di applicare una tecnica di riduzione della dimensionalità, ossia la PCA (Principal Component Analysis). Si è creata quindi una matrice cliente-prodotto con:

- righe → tessera fedeltà (unico modo per ricondurre l'acquisto ad un cliente);
- colonne → prodotti.

I valori sono le frequenze di acquisto di un prodotto per un dato cliente. La PCA ci permette di ridurre il numero di variabili, mantenendo solo la varianza e di eliminare correlazioni e rumore.

La maledizione della dimensionalità del KMeans è mitigata dalla PCA. Sui dati ridotti è stato poi applicato il KMeans e per la scelta del numero ottimale sono stati utilizzati due criteri:

- metodo del gomito (elbow), basato sull'analisi del numero di cluster e ...;
- silhouette score, che misura la separazione tra i cluster.

La soluzione ottimale trovata è di 3 cluster. La maggior parte dei clienti appartiene al cluster 0 (circa l'88%) e il restante alle restanti due classi.

Confrontando ciascun cluster con le frequenze dei prodotti acquistati si è osservato che:

- **Cluster 0 – Cliente standard (88,1%)**: maggioranza dei clienti con acquisti bilanciati;
- **Cluster 2 – Cliente con acquisti consistenti (11,5%)**: minoranza probabilmente famiglie o gestori di attività;
- **Cluster 1 – Pet lovers (0,4%)**: quelli in minor parte, che hanno un focus sui prodotti per gli animali.

I gruppi che si sono trovati sono suddivisi principalmente per intensità di acquisto e tipologia.

Le informazioni estratte ci permettono di avere informazioni su:

- la variabilità delle frequenze dei prodotti acquistati nel tempo;
- le associazioni tra prodotti;
- l'individuazione di gruppi di clienti con comportamenti simili.

Questi risultati offrono spunti concreti per ottimizzare la gestione del punto vendita: è possibile identificare prodotti da promuovere o da ridurre, progettare offerte mirate e pianificare promozioni personalizzate per specifiche categorie di clienti, massimizzando così l'efficacia commerciale

