FITBIT DAILY - DESCRIPTION

venerdì 2 ottobre 2026 18:31

MICCICHE' FLAVIO - 1000059576

Il dataset **patients** analizzato, contiene informazioni sui pazienti che vengono divisi in quattro casi clinici:

- **Alzehimer (AD);**
- **Parkinson (PD);**
- **Sclerosi Multipla (SM);**
- **Controllo Sano (CONT).**

Questi saranno la nostra classe (target) per ogni paziente.

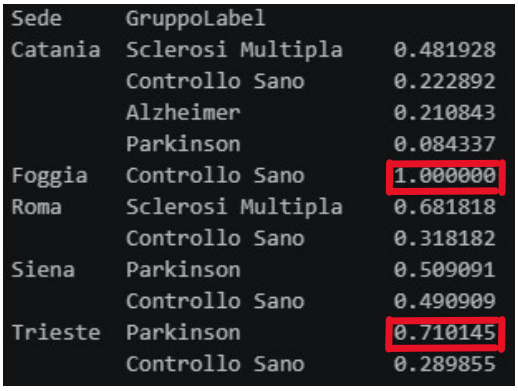
Il secondo dataset, **fitbit_daily**, contiene misure giornaliere registrate dal Fitbit per ogni paziente. Le misure riguardano:

- **Attività fisica:** Calories, ActivityCalories, Distance, Steps, RestingHeartRate, Sedentary / LightlyActive /Moderately Active / VeryActiveMinutes.
- **Zone cardiache:** con calorie e minutaggio per ogni zona (BelowFatBurn, FatBurn, Cardio, Peak);
- **Sonno**:
  - **Parametri generali:** VO2Max, NightlySkinTemperature,MinutesAfterWakeup, SleepEfficiency, MinutesToFallAsleep, TimeInBed;
  - **Parametri per ogni fase:** conteggio e minutaggio in LightSleep, DeepSleep, REMSleep o Awake;
  - **Parametri di respirazione:** BreathingRate (complessivo e specifico per ogni fase del sonno).

Questo dataset fornisce le **feature** utilizzate per **addestrare i modelli di classificazione**.

Nel processo di preparazione dei dati sono state applicate diverse operazioni di pulizia, selezione e trasformazione delle variabili, con l'obiettivo di ottenere un dataset coerente, privo di ridondanze e adeguato alle fasi successive di analisi esplorativa, PCA e addestramento dei modelli di classificazione.

Nel dataset *patients*, alcune variabili sono state eliminate in quanto non rilevanti ai fini della classificazione.
In particolare, *Centro* e *Sede* sono state rimosse perché presentano una distribuzione fortemente sbilanciata rispetto ai gruppi clinici: alcune sedi contengono quasi esclusivamente una singola patologia (ad esempio Foggia → solo Controllo Sano, Trieste → quasi esclusivamente Parkinson, Roma → prevalenza di Sclerosi Multipla). L'inclusione di tali variabili avrebbe portato il modello ad associare la sede alla patologia invece che ai dati fisiologici raccolti tramite Fitbit.
Sono state inoltre eliminate le variabili *Gruppo* e *PatologiaPrincipale*, quasi identiche a GruppoLabel, evitando duplicazioni informative.



Sede	GruppoLabel	
Catania	Sclerosi Multipla	0.481928
	Controllo Sano	0.222892
	Alzheimer	0.210843
	Parkinson	0.084337
Foggia	Controllo Sano	1.000000
Roma	Sclerosi Multipla	0.681818
	Controllo Sano	0.318182
Siena	Parkinson	0.509091
	Controllo Sano	0.490909
Trieste	Parkinson	0.710145
	Controllo Sano	0.289855

Nel dataset *fitbit_daily* sono state rimosse le variabili relative ai conteggi delle fasi di sonno (ad es. *LightSleepCounts*, *DeepSleepCounts*, *REMSleepCounts*,…) e la variabile *TimeInBed*. L'analisi delle correlazioni ha mostrato che tali misure sono fortemente ridondanti rispetto alle corrispondenti misure in minuti (es. *LightSleepMinutes*, *DeepSleepMinutes*, *REMSleepMinutes*). La presenza simultanea di entrambe le versioni avrebbe introdotto multicollinearità senza apportare nuova

informazione utile al modello.

	TimeInBed	LightSleepMinutes	LightSleepCounts	DeepSleepMinutes	DeepSleepCounts
TimeInBed	1.000000	0.807898	0.697838	0.578898	0.534494
LightSleepMinutes	0.807898	1.000000	0.767751	0.447819	0.526315
LightSleepCounts	0.697838	0.767751	1.000000	0.615380	0.672183
DeepSleepMinutes	0.578898	0.447819	0.615380	1.000000	0.698077
DeepSleepCounts	0.534494	0.526315	0.672183	0.698077	1.000000
REMSleepMinutes	0.610723	0.464012	0.546832	0.659537	0.523072
REMSleepCounts	0.544275	0.453334	0.635735	0.642387	0.548359
AwakeMinutes	0.762013	0.755124	0.682137	0.462429	0.479498
AwakeCounts	0.655382	0.627489	0.930764	0.598913	0.590544
AsleepMinutes	0.990893	0.775385	0.663922	0.572626	0.518031
AsleepCounts	0.712194	0.738631	0.971958	0.698013	0.753113

	REMSleepMinutes	REMSleepCounts	AwakeMinutes	AwakeCounts	AsleepMinutes	AsleepCounts
TimeInBed	0.610723	0.544275	0.762013	0.655382	0.990893	0.712194
LightSleepMinutes	0.464012	0.453334	0.755124	0.627489	0.775385	0.738631
LightSleepCounts	0.546832	0.635735	0.682137	0.930764	0.663922	0.971958
DeepSleepMinutes	0.659537	0.642387	0.462429	0.598913	0.572626	0.698013
DeepSleepCounts	0.523072	0.548359	0.479498	0.590544	0.518031	0.753113
REMSleepMinutes	1.000000	0.770949	0.425721	0.518880	0.616530	0.659163
REMSleepCounts	0.770949	1.000000	0.419996	0.695259	0.541361	0.785316
AwakeMinutes	0.425721	0.419996	1.000000	0.604791	0.670844	0.662154
AwakeCounts	0.518880	0.695259	0.604791	1.000000	0.629663	0.926703
AsleepMinutes	0.616530	0.541361	0.670844	0.629663	1.000000	0.684788
AsleepCounts	0.659163	0.785316	0.662154	0.926703	0.684788	1.000000

Analogamente, è stata verificata la correlazione tra le variabili delle zone cardiache (*BelowFatBurnCalories*, *FatBurnCalories*, *CardioCalories*, *PeakCalories* e le corrispondenti misure in minuti). In questo caso le correlazioni non hanno evidenziato ridondanze tali da giustificare la rimozione delle variabili, che sono state quindi mantenute

Nel dataset *patients* non sono presenti valori mancanti significativi, pertanto non è stata necessaria alcuna imputazione.

Nel dataset *fitbit_daily*, invece, sono presenti due tipologie di valori mancanti:

1. **Valori mancanti fisiologici**, tipici delle misure di sonno (ad esempio *MinutesAfterWakeup*, *MinutesToFallAsleep*, *AwakeMinutes*, *LightSleepMinutes*, *DeepSleepMinutes*, *REMSleepMinutes*). In questi casi il valore mancante indica semplicemente che il paziente non ha registrato quella fase di sonno. Per evitare di introdurre rumore, tali valori sono stati imputati a 0.
2. **Valori mancanti non fisiologici**, presenti in variabili come *Calories*, *ActivityCalories*, *RestingHeartRate*, *VO2Max*, *NightlySkinTemperature*, *BreathingRate* e nelle misure delle zone cardiache. In questi casi l'assenza del dato non è interpretabile come "assenza di attività", pertanto è stata applicata un'imputazione con la mediana della colonna, scelta robusta rispetto a valori anomali.

Infine, alcune variabili presentavano una percentuale di valori mancanti superiore al 50% (ad esempio *LightSleepBreathingRate*, *DeepSleepBreathingRate*, *REMSleepBreathingRate*). Poiché una imputazione massiva avrebbe compromesso la qualità del dato, tali variabili sono state eliminate. Variabili con percentuali intermedie (30–60%), come *FullSleepBreathingRate*, sono state invece mantenute e imputate con la mediana.

Nel dataset *patients*, la variabile *Sesso* è stata trasformata in formato numerico (0 = femmina, 1 = maschio) e la variabile *DataNascita* è stata convertita in *Età*, ottenendo delle misure più adatte alle analisi statistiche e ai modelli.

Nel dataset *fitbit_daily* tutte le variabili sono già numeriche, pertanto non è stato necessario alcun encoding aggiuntivo.

Terminata la fase di preprocessing si è stabilito di fare il merging tra *patients* e *fitbit_daily* con superchiave PatientID e Day, che andrà rimossa prima dell'analisi esplorativa.

Durante tale fase è stato rilevato che il paziente **RM-CONT-03** è presente nel dataset Fitbit ma assente nel dataset anagrafico. Poiché non dispone delle informazioni essenziali per la

classificazione (sesso, età, gruppo clinico), tale paziente è stato escluso dal dataset finale utilizzato per l'addestramento dei modelli. I suoi dati Fitbit rimangono disponibili per eventuali analisi esplorative o per una predizione finale.

PRIMA:

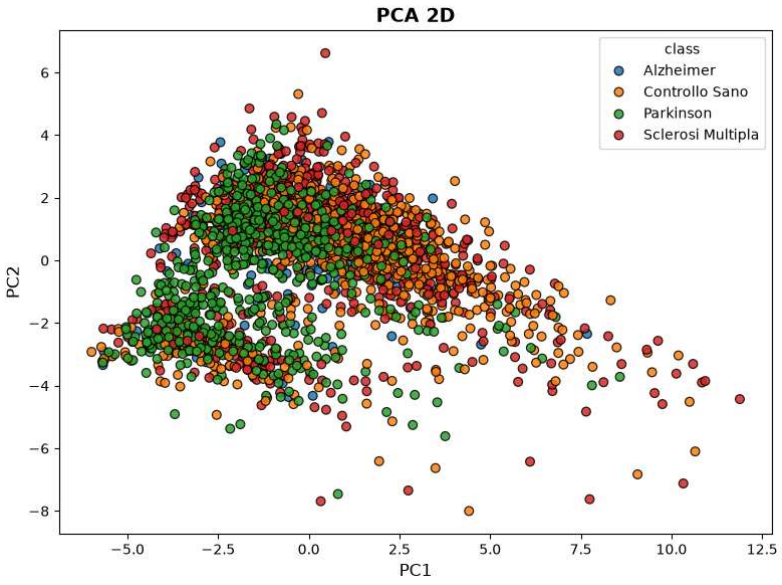
```
 ...  ...                        ...    ...          ...
 28  BreathingRate               2566 non-null   float64
 29  FullSleepBreathingRate      2566 non-null   float64
 30  Sesso                       0 non-null      float64
 31  GruppoLabel                 2558 non-null   str
 32  Età                         2558 non-null   float64
dtypes: float64(24), int64(6), str(3)
memory usage: 764.5 KB
None
```

DOPO:

```
 ...  ...                        ...    ...          ...
 28  BreathingRate               2558 non-null   float64
 29  FullSleepBreathingRate      2558 non-null   float64
 30  Sesso                       2558 non-null   int64
 31  GruppoLabel                 2558 non-null   str
 32  Età                         2558 non-null   int32
dtypes: float64(22), int32(1), int64(7), str(3)
memory usage: 752.8 KB
None
```

Dopo aver unificato il dataset e ridotto le feature, abbiamo applicato la PCA con 2 componenti per una semplice analisi esplorativa.
Le prime due componenti riescono a spiegare circa il **34% della varianza**, quindi catturano solo una parte dell'informazione totale:

```
Explained variance ratio: [0.22658005 0.12813294]
```



Il grafico mostra una **separazione parziale** tra i gruppi clinici: i *Controlli Sani* tendono a formare un cluster più compatto, mentre *Alzheimer*, *Parkinson* e soprattutto *Sclerosi Multipla* risultano più dispersi.

Le classi patologiche **si sovrappongono** in modo evidente, segno che le differenze tra i gruppi non sono linearmente separabili nelle prime due componenti.

In altre parole, la PCA **non permette di distinguere chiaramente i quattro gruppi**.
La maggior parte dell'informazione è distribuita nelle componenti successive o in combinazioni non lineari delle feature.

la fase successiva è stata dedicata alla costruzione di modelli di classificazione.

I modelli scelti per la classificazione sono:
Alberi di decisione -> modello di base per la classificazione;
Random Forest -> migliora le capacità attraverso insieme di alberi;
K-Nearest Neighbors -> basato sulla distanza tra le osservazioni;
SVC(Support Vector Classifier) -> utilizzato per individuare dei confini decisionali;

Prima di costruire i già citati modelli di classificazione si è diviso il dataset in training set e test set.

Solo dopo questa divisione si è creata la pipeline che:

- Fa scaling dei dati tramite StandardScaler;
- Addestra il classificatore sul training set;
- Ottimizza gli iper-parametri principali dei modelli attraverso GridSearchCV

Gli iper-parametri variano per ogni modello, dato che sono influenzati dalla propria natura.

Albero di decisione	Profondità albero:
	`"clf__max_depth": [None, 5, 10, 20],`
	Numero campioni richiesto per dividere un nodo interno:
	`"clf__min_samples_split": [2, 5, 10]`

Random Forest	Numero di alberi presenti:
	`"clf__n_estimators" : [50,100],`
	Profondità massima:
	`"clf__max_depth" : [None, 10, 20]`

SVC	Parametro di regolarizzazione:
	`"clf__C" : [0.1, 1, 10],`
	Confine lineare o non lineare:
	`"clf__kernel" : ["linear", "rbf"]`

KNN	Numero vicini considerati:
	`"clf__n_neighbors" : [3, 5, 7],`
	Contributo dei vicini:
	`"clf__weights": ["uniform", "distance"]`

I modelli sono stati valutati sul test set utilizzando l'**accuracy** come metrica iniziale.

Dall'analisi dei risultati emerge che tutti i modelli hanno ottenuto performance solide, con differenze legate soprattutto alla loro capacità di cogliere pattern non lineari nelle misure Fitbit. Tra i modelli testati, **Random Forest** ha raggiunto l'accuratezza più elevata (81%), seguito da **SVC** (78%), **Decision Tree** (73%) e **K-NN** (71%).

Di seguito una breve descrizione dei modelli con i parametri ottimizzati tramite GridSearchCV:

Model	Best params	Test accuracy
Albero di decisione	'clf__max_depth': None, 'clf__min_samples_split': 10	0.73
Random Forest	{'clf__max_depth': None, 'clf__n_estimators': 50}	0.81
SVC	{'clf__C': 1, 'clf__kernel': 'rbf'}	0.785
KNN	{'clf__n_neighbors': 5, 'clf__weights': 'uniform'}	0.71

Per ridurre ulteriormente la presenza di dati fitbit molto variabili e rumorosi, sono stati applicati i concetti di **Bagging** e **Boosting**, ossia due tecniche dell'Ensemble Learning che permettono rispettivamente di utilizzare modelli in parallelo o in modo sequenziale.

In particolare abbiamo applicato il bagging all'Albero di decisione, SVC e KNN e invece il boosting solo all'albero di decisione. I risultati sono i seguenti:

```
Bagging Decision Tree accuracy: 0.8515625
Boosting Decision Tree accuracy: 0.73046875
Bagging K-NN accuracy: 0.49609375
Bagging SVC accuracy: 0.474609375
```

Il Bagging Decision Tree è il modello più accurato tra gli ensemble: il bagging riduce la varianza del singolo albero e stabilizza la classificazione, migliorando nettamente rispetto al Decision Tree semplice. La combinazione di molti alberi addestrati su sotto-campioni diversi ha gestito bene la variabilità dei dati Fitbit.

Il bagging, per il resto, non porta benefici a modelli già stabili come SVC e K-NN, mentre il boosting del Decision Tree resta competitivo ma meno efficace del bagging in questo dataset.

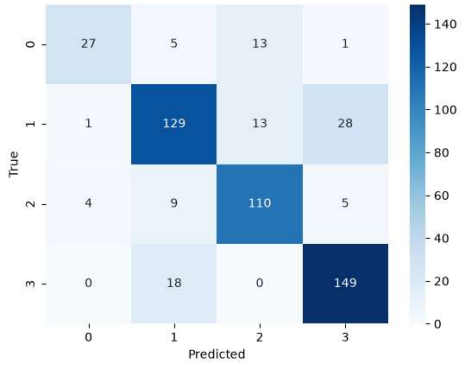
I due modelli **più accurati** sono il **Bagging Decision Tree (85%)** e il **Random Forest (81%)**. Per questi modelli verranno calcolate le metriche avanzate (classification report, confusion matrix, ROC/AUC binarizzato) al fine di ottenere una valutazione più completa della loro capacità di distinguere i gruppi clinici.

Per quanto riguarda il **Random Forest**, dall'analisi del classification report emerge che le classi **Parkinson** e **Sclerosi Multipla** sono le **più riconosciute** (si noti l'F1-score), invece **Alzheimer** è la più **complessa da classificare** (con **recall** pari a **0.59**), quindi questo caso clinico viene **confuso con le altre categorie**.
Dalla differenza tra le misure di macro e weighted average si evince un lieve **sbilanciamento nella distribuzione delle classi**, poiché le classi più numerose **influenzano maggiormente la media pesata**. L'analisi della confusion matrix conferma quanto detto sul classification report.

```
=== CLASSIFICATION REPORT & CONFUSION MATRIX (RF) ===
                  precision    recall  f1-score   support

       Alzheimer       0.84      0.59      0.69        46
   Controllo Sano      0.80      0.75      0.78       171
       Parkinson       0.81      0.86      0.83       128
Sclerosi Multipla      0.81      0.89      0.85       167

        accuracy                           0.81       512
       macro avg       0.82      0.77      0.79       512
    weighted avg       0.81      0.81      0.81       512
```



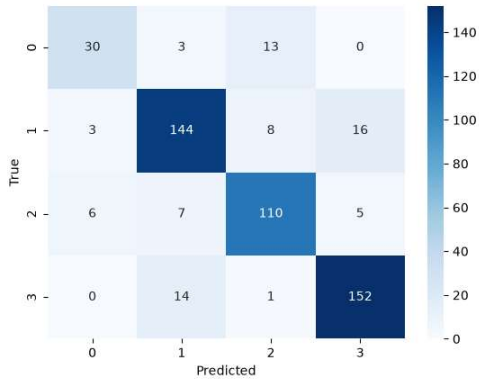
Nella validazione del **Bagging DT** abbiamo ottenuto **risultati superiori** rispetto al Random Forest.

Il classification report mostra un **miglioramento su tutte le classi** (si noti l'F1-score), le metriche macro e weighted average lo confermano perché la differenza è minima, e risulta, seppur di poco, più **efficace l'identificazione** dei **pazienti affetti da Alzheimer** e **Sclerosi Multipla**, **riducendo** il numero di **errori osservati** nella confusion matrix.

```
=== CLASSIFICATION REPORT & CONFUSION MATRIX (Bagg-DT) ===
                  precision    recall  f1-score   support

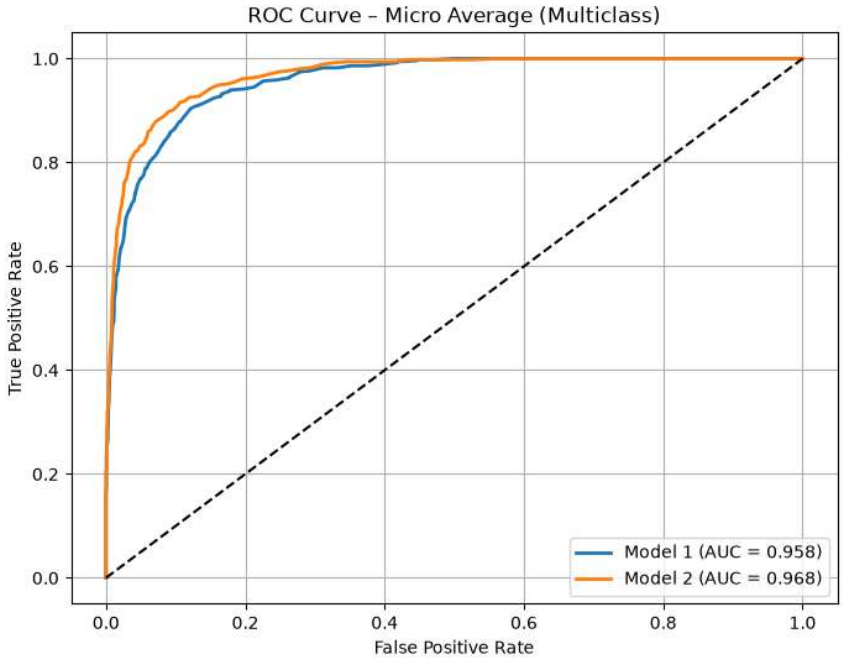
       Alzheimer       0.77      0.65      0.71        46
   Controllo Sano      0.86      0.84      0.85       171
       Parkinson       0.83      0.86      0.85       128
Sclerosi Multipla      0.88      0.91      0.89       167

        accuracy                           0.85       512
       macro avg       0.83      0.82      0.82       512
    weighted avg       0.85      0.85      0.85       512
```



Per fornire un'ultima conferma del modello migliore fra i due è stata utilizzata una **ROC Curve multiclass basata sulla micro-average**.

La strategia micro-average considera simultaneamente tutte le decisioni di classificazione e permette di **sintetizzare il problema multiclasse in un'unica curva ROC**.
Ciò è stato possibile grazie alle funzioni **label_binarize()** e **ravel()**.
La prima ha consentito di trasformare il problema multiclasse in una **rappresentazione binaria (one-vs-rest)**, mentre la seconda ha convertito la matrice risultante in un **vettore monodimensionale**.



Entrambi i modelli mostrano una **capacità discriminante molto elevata** (**AUC > 0.95**), tuttavia il Bagging Decision Tree presenta una **curva ROC leggermente superiore** e un valore di **AUC più elevato**.
Possiamo dunque **confermare** il **Bagging Decision Tree** come **miglior classificatore per il dataset Fitbit**.