

SECOND CLASSWORK - DESCRIPTION

domenica 27 settembre 2026 18:20

MICCICHE' FLAVIO - 1000059576

Il dataset analizzato, formato in formato Excel, contiene informazioni sui bambini che vengono divisi in tre categorie:

- **ASD** -> bambini con diagnosi di autismo;
- **GDD** -> bambini con ritardo globale dello sviluppo;
- **Controlli** -> bambini con sviluppo tipico.

Ogni paziente è descritto da diverse caratteristiche misurate attraverso scale cliniche con valori compresi tra 0, 1 e 2.

Alcune variabili al fine della classificazione sono state rimosse. Le variabili rimosse sono le seguenti:

- Età cronologica (mesi);
- **Scala B** -> score totale della scala 'comunicazione e linguaggio';
- **Scala D** -> score totale della scala 'personale, sociale ed emotiva';
- **TOT.** -> score totale per tutte le scale;
- **Score di rischio** -> etichetta derivata dal punteggio complessivo;

Inoltre, per evitare che i valori di default (values = 0) potessero introdurre rumore nei dati, sono stati rimossi i bambini con 'Età equivalente' inferiore ai 12 mesi.

L'età equivalente è stata mantenuta, infatti rappresenta una misura sintetica e significativa dello sviluppo del bambino. Essa si riferisce all'età non reale ma quella dimostrata o calcolata attraverso i punteggi ottenuti nelle scale di valutazione considerate.


Per quanto riguarda la variabile 'Sesso' è stata mantenuta in quanto non è stato indicato diversamente nella consegna. Dato che la variabile è categorica, è stata mappata in forma numerica prima dell'applicazione della PCA.

Terminata la fase di pre-processing sui tre fogli, si è stabilito di concatenare in un unico dataframe i tre dataset, così da consentire l'applicazione della PCA su tutti i dati in modo compatto e facilitarne la visualizzazione comparativa tra le classi.

Le prime due componenti principali selezionate spiegano complessivamente circa il 34% della varianza totale del dataset. Ciò indica che una parte significativa è anche distribuita anche nelle componenti successive:

```
Explained variance ratio: [0.23758323 0.10392344]
```

Il grafico che segue è la rappresentazione dei dati ridotti mediante PCA(2 dimensioni).



L'analisi PCA in 2D mostra una separazione parziale tra le tre classi. I bambini con sviluppo tipico sono concentrati in una regione compatta, mentre i soggetti ASD e GDD presentano maggiore dispersione (anche se GDD in minore quantità). Si osserva una sovrapposizione considerevole tra le classi GDD e Controlli, indicando una separazione non completamente lineare.

La PCA in questa fase è stata utilizzata esclusivamente a scopo esplorativo e di visualizzazione, mentre la fase successiva è stata dedicata alla costruzione di modelli di classificazione

I modelli richiesti per la classificazione sono:

- **Alberi di decisione** -> modello di base per la classificazione;
- **Random Forest** -> migliora le capacità attraverso insieme di alberi;
- **K-Nearest Neighbors** -> basato sulla distanza tra le osservazioni;
- **SVC(Support Vector Classifier)** -> utilizzato per individuare dei confini decisionali;

Prima di costruire i già citati modelli di classificazione si è diviso il dataset in training set e test set. Solo dopo questa divisione si è creata la pipeline che:

- Fa scaling dei dati tramite StandardScaler;
- Addestra il classificatore sul training set;
- Ottimizza gli iper-parametri principali dei modelli attraverso GridSearchCV

Gli iper-parametri variano per ogni modello, dato che sono influenzati dalla propria natura.

Albero di decisione	Profondità albero: <code>"clf_max_depth": [None, 5, 10, 20],</code> Numero campioni richiesto per dividere un nodo interno: <code>"clf_min_samples_split": [2, 5, 10]</code>
Random Forest	Numero di alberi presenti: <code>"clf_n_estimators" : [50,100],</code> Profondità massima: <code>"clf_max_depth" : [None, 10, 20]</code>
SVC	Parametro di regolarizzazione: <code>"clf_C" : [0.1, 1, 10],</code> Confine lineare o non lineare: <code>"clf_kernel" : ["linear", "rbf"]</code>
KNN	Numero vicini considerati: <code>"clf_n_neighbors" : [3, 5, 7],</code> Contributo dei vicini: <code>"clf_weights": ["uniform", "distance"]</code>

I modelli sono stati valutati sul test set utilizzando l'**accuracy** come metrica principale.

Dall'analisi dei risultati emerge che gli Alberi di decisione hanno ottenuto la maggiore accuratezza sul test set (62.5%), seguito da SVC (60%), Random Forest (57.5%) e K-NN (55%). In generale, la classificazione risulta di difficile per la distinzione tra GDD e Controlli, come evidenziato anche nella PCA, mentre i casi ASD più marcati sono stati più facilmente identificati

Di seguito sono riportati i risultati, compresi i parametri ottimizzati attraverso GridSearchCV.

Model	Best params	Test accuracy
Albero di decisione	'clf__max_depth': None, 'clf__min_samples_split': 10	0.625
Random Forest	{'clf__max_depth': None, 'clf__n_estimators': 50}	0.575
SVC	{'clf__C': 1, 'clf__kernel': 'rbf'}	0.6
KNN	{'clf__n_neighbors': 5, 'clf__weights': 'uniform'}	0.55

Per migliorare le prestazioni dei modelli di classificazione e ridurre il rischio di **overfitting** o di errori su casi difficili, sono stati applicati i concetti di **Bagging** e **Boosting**, ossia due tecniche che permettono rispettivamente di utilizzare modelli in parallelo o in modo sequenziale.

In particolare abbiamo applicato il bagginè all'Albero di decisione, SVC e KNN e invece il boosting solo all'albero di decisione. I risultati sono i seguenti:

```
Bagging Decision Tree accuracy: 0.6  
Boosting Decision Tree accuracy: 0.55  
Bagging SVC accuracy: 0.575  
Bagging K-NN accuracy: 0.575
```

L'uso di Bagging e Boosting non ha portato a un miglioramento dell'accuracy rispetto ai modelli base; in alcuni casi, le prestazioni sono leggermente peggiori. Tuttavia, queste tecniche hanno permesso di stabilizzare le predizioni e confermare l'eterogeneità e la sovrapposizione delle classi osservata nella PCA.